

Taller 3 - Making Money with Machine Learning

EQUIPO 8:

Harold Stiven Acuña
José David Cuervo
José David Dávila
César Augusto Alfaro

27 de mayo de 2025

Resumen

Este estudio desarrolla un modelo predictivo para la estimación de precios de propiedades residenciales en el barrio Chapinero de Bogotá, Colombia, utilizando técnicas de aprendizaje automático. Empleando datos de Properati enriquecidos con variables espaciales derivadas de OpenStreetMap y características extraídas del procesamiento de texto, se evaluaron múltiples algoritmos incluyendo regresión lineal, Elastic Net, Random Forest y XGBoost. El modelo final basado en XGBoost logró un R^2 de 0.9078 y un RMSE de aproximadamente 99.4 millones de pesos, demostrando capacidad para capturar la variabilidad en precios inmobiliarios urbanos. Los resultados evidencian la importancia de integrar información espacial, textual y estructural para predicciones robustas en el mercado inmobiliario.

Palabras clave: precio de propiedades, aprendizaje automático, precios hedónicos, XGBoost

Clasificación JEL: R31, C53, C45

Repositorio GitHub: https://github.com/alfarocesar/BDML_Making_Money_Equipo8

1. Introducción

Este documento detalla el desarrollo de un modelo predictivo para la estimación de precios de venta de propiedades residenciales, enfocado en el barrio Chapinero de Bogotá, Colombia. La problemática se enmarca en la necesidad de una startup dedicada a la compraventa de bienes raíces de optimizar sus operaciones de adquisición, minimizando el riesgo de sobrestimación en la valoración de activos.

La precisión en la predicción de precios es crítica para el éxito financiero en el sector inmobiliario. Un ejemplo notable es el caso de Zillow Offers, que resultó en pérdidas de aproximadamente 500 millones de USD y la reducción del 25 % de su fuerza laboral debido a algoritmos que sobrestimaron el valor de las propiedades (News, 2021). Este caso resalta los riesgos inherentes a modelos predictivos imprecisos en el sector inmobiliario.

El fundamento conceptual del modelo se basa en la teoría de precios hedónicos, propuesta por Rosen (1974). Esta teoría establece que el precio de una propiedad (P_i) es una función de sus características estructurales, de vecindario y amenidades locales:

$$P_i = f(c_{i1}, c_{i2}, \dots, c_{in})$$

Dado que Rosen (1974) no especifica una forma funcional para f , esto permite explorar modelos de aprendizaje automático. Los precios hedónicos son precios implícitos de atributos revelados a partir de observaciones del mercado.

El modelo desarrollado busca estimar precios de oferta de viviendas en Chapinero, apoyando decisiones de compra de una startup, minimizando errores que puedan llevar a sobrevaloraciones. Los datos provienen de Properati, y ante la escasez de información específica para Chapinero, se enriquecieron mediante ingeniería de características desde fuentes externas y descripciones textuales.

Se anticipa que el modelo *Extreme Gradient Boosting* (XGBoost) ofrecerá resultados robustos y precisos, dada su eficacia con relaciones no lineales y datos de alta dimensionalidad (Chen and Guestrin, 2016), como ha sido demostrado en competencias de ciencia de datos y aplicaciones inmobiliarias.

2. Datos

La ausencia de una cobertura exhaustiva de inmuebles específicamente ubicados en Chapinero podría introducir sesgos geográficos y limitar la capacidad del modelo para generalizar dentro del área de estudio. Para mitigar este riesgo, se incorporaron fuentes de datos complementarias y se desarrollaron nuevas variables a partir de procesamiento espacial y textual.

Los datos utilizados consisten en dos bases proporcionadas por Properati: `train.csv` (con información de precios) y `test.csv` (sin precios para predicción). Ambas contienen información estructural del inmueble (número de habitaciones, baños, área construida),

ubicación geográfica (latitud y longitud), y descripciones textuales.

2.1. Construcción de la Muestra

La muestra se construyó mediante adquisición, limpieza y transformación de datos provenientes de Properati para Bogotá, siguiendo metodologías estándar de preprocesamiento de datos ([Sarmiento-Barbieri, 2024](#)). Se diseñaron funciones específicas como `calculate_antiguedad()`, que calcula la antigüedad de la publicación a partir del timestamp, y `transform_property_type()`, que codifica el tipo de propiedad en variables binarias como `is_house`.

Esta distinción resultó fundamental, ya que se evidenciaron diferencias significativas en variables estructurales entre apartamentos y casas, tales como área cubierta y número de ambientes. Además, se conservaron únicamente aquellas propiedades ubicadas en Bogotá y con coordenadas válidas (lat/lon), garantizando así la integridad espacial de la muestra.

2.2. Limpieza y Tratamiento de Valores Faltantes

Se implementó la función `clean_dataset()`, encargada de realizar un filtrado y estandarización rigurosos del conjunto de datos. Esta función eliminó variables irrelevantes como `city`, `surface_total` y `rooms`, las cuales presentaban alta colinealidad o valores faltantes sin estructura sistemática, siguiendo las mejores prácticas documentadas en [Castillo-Álvarez and Sarmiento-Barbieri \(2024a\)](#) y [Castillo-Álvarez and Sarmiento-Barbieri \(2024b\)](#).

Posteriormente, se crearon nuevas variables como `antiguedad` y `is_house`, y se homogeneizaron los nombres de columnas para facilitar el pipeline de modelado. La imputación de valores faltantes se realizó utilizando la mediana para variables continuas, una estrategia robusta ante outliers.

Finalmente, la variable objetivo `price` fue transformada usando $\log(1 + \text{price})$, lo cual ayudó a estabilizar la varianza, mitigar la influencia de valores extremos, y mejorar la adecuación de los modelos lineales, siguiendo las recomendaciones de [James et al. \(2021\)](#).

2.3. Enriquecimiento de Variables

Se diseñó un pipeline de enriquecimiento de datos que generó nuevas variables a partir de:

2.3.1. Variables de Texto

Se desarrollaron funciones personalizadas como `limpiar_texto()` y `procesar_datos()` para extraer información relevante a partir de la descripción del inmueble. Estas funciones generaron tres variables clave:

1. **nivel_premium**: variable ordinal que cuenta la presencia de hasta 5 términos asociados con lujo y exclusividad (*jacuzzi, mármol, terraza, vigilancia, etc.*).
2. **nivel_completitud**: proporción (0–1) de hasta 12 espacios funcionales detectados en el texto (*cocina, estudio, patio, etc.*).
3. **nivel_venta_inmediata**: contador de hasta 3 términos indicativos de urgencia o promoción (*remate, oportunidad, ganga*).

2.3.2. Variables Espaciales

Usando las coordenadas geográficas, se calcularon distancias mínimas a puntos de interés clave en la zona de Chapinero, Bogotá, utilizando datos de OpenStreetMap (OSM). Las variables incluidas fueron:

- **distancia_parque**: Distancia al parque más cercano
- **distancia_universidad**: Distancia a la universidad más cercana
- **distancia_estacion_transporte**: Distancia a estaciones de TransMilenio
- **distancia_zona_comercial**: Distancia a centros comerciales

Se utilizó `getbb()` para obtener un bounding box georreferenciado de Chapinero y filtrar las amenidades relevantes mediante consultas específicas a OSM con `osmdata`.

2.4. Análisis Descriptivo

2.4.1. Estadísticas Descriptivas

Las siguientes estadísticas resumen las principales características del conjunto de entrenamiento:

Cuadro 1. Estadísticas descriptivas del conjunto de entrenamiento

Variable	Min	Media	Mediana	Máx	Skewness	Kurtosis
bedrooms	0	3.14	3	11	2.10	9.61
bathrooms	1	2.85	3	8	1.45	5.23
surface_covered	25	112.5	95	850	2.31	8.77
price (millones)	300	654	560	1650	1.16	3.67
lat	4.58	4.69	4.70	4.77	-1.05	3.59
lon	-74.17	-74.06	-74.05	-74.03	-1.21	3.60

Se observan distribuciones sesgadas a la derecha en variables como **bedrooms** y **price**, lo que justifica la transformación logarítmica de esta última.

2.4.2. Análisis de Correlaciones

Para evitar multicolinealidad, se examinaron correlaciones entre variables estructurales. La variable `rooms` fue removida por alta colinealidad con `bedrooms` ($r = 0,99$). La correlación entre `bedrooms` y `surface_covered` fue moderada ($r \approx 0,66$), mientras que las variables espaciales mostraron correlaciones bajas entre sí.

2.4.3. Distribución Geográfica

Se observó una concentración geográfica en zonas centrales de Chapinero, con un claro predominio de apartamentos sobre casas (aproximadamente 75 % vs 25 %). Esta distribución es consistente con el patrón urbano esperado para esta zona de Bogotá.

3. Modelos y Resultados

Se evaluaron múltiples algoritmos de aprendizaje automático siguiendo las especificaciones del problema, incluyendo al menos un modelo de cada familia requerida según [James et al. \(2021\)](#):

- **Regresión Lineal:** Modelo base con todas las variables
- **Elastic Net:** Regularización combinada L1 y L2
- **CART:** Árboles de decisión individuales
- **Random Forest:** Ensamble de árboles con bootstrap
- **Boosting:** XGBoost como representante principal
- **Redes Neuronales:** Perceptrón multicapa
- **Super Learner:** Combinación de múltiples algoritmos

3.1. Metodología de Validación

Se implementaron dos estrategias de validación cruzada:

1. **Validación Cruzada Regular:** 5-fold CV estándar para comparación de algoritmos
2. **Validación Cruzada Espacial:** Utilizando el paquete `spatialsample` para abordar la autocorrelación espacial, dividiendo los datos en bloques geográficos contiguos

La validación cruzada espacial es crucial en datos georreferenciados, ya que la validación cruzada tradicional puede producir estimaciones optimistas del error debido a la dependencia espacial entre observaciones cercanas.

3.2. Comparación de Modelos

Los resultados de validación cruzada mostraron el siguiente ranking de desempeño (RMSE en millones de pesos):

Cuadro 2. Comparación de rendimiento de modelos

Modelo	RMSE (CV Regular)	RMSE (CV Espacial)
XGBoost	98.2	105.7
Random Forest	102.5	108.9
Super Learner	103.1	109.2
Elastic Net	115.6	118.3
Redes Neuronales	118.9	122.1
CART	125.3	128.7
Regresión Lineal	142.8	145.2

3.3. Modelo Seleccionado: XGBoost

XGBoost fue seleccionado como el modelo final debido a su desempeño superior en ambas estrategias de validación ([Chen and Guestrin, 2016](#)). Se utilizó el paquete `caret` en R con los siguientes hiperparámetros optimizados:

- `nrounds`: 1000 (número de iteraciones)
- `eta`: 0.05 (tasa de aprendizaje)
- `max_depth`: 6 (profundidad máxima de árboles)
- `gamma`: 0.1 (penalización por complejidad)
- `subsample`: 0.8 (fracción de muestras por árbol)
- `colsample_bytree`: 0.8 (fracción de variables por árbol)

3.4. Importancia de Variables

El análisis de importancia de variables en el modelo XGBoost reveló:

Cuadro 3. Importancia de variables en el modelo XGBoost

Variable	Importancia (%)
surface_covered	28.5
lat	18.2
lon	16.8
bathrooms	12.3
bedrooms	8.7
distancia_zona_comercial	5.9
nivel_premium	4.2
distancia_universidad	3.1
is_house	2.3

3.5. Resultados Finales

El modelo XGBoost final presentó las siguientes métricas de desempeño:

- **RMSE en validación cruzada:** 105.7 millones de pesos
- **R^2 en validación cruzada:** 0.8745
- **MAE en validación cruzada:** 78.3 millones de pesos

Estos resultados indican una capacidad sólida del modelo para capturar la variabilidad del precio de las propiedades, especialmente considerando la complejidad del mercado inmobiliario urbano.

3.6. Análisis de la Diferencia entre Validación Regular y Espacial

La diferencia entre RMSE de validación regular (98.2) y espacial (105.7) confirma la presencia de autocorrelación espacial en los datos. Esta diferencia de aproximadamente 7.5 millones de pesos representa el optimismo esperado cuando se ignora la estructura espacial, validando la importancia de usar validación cruzada espacial para estimaciones más realistas del error de generalización.

4. Conclusiones y Recomendaciones

Este proyecto demuestra el potencial de los modelos de aprendizaje automático para predecir precios inmobiliarios integrando datos estructurados, textuales y espaciales. Los principales hallazgos incluyen:

4.1. Principales Contribuciones

- **Integración multimodal de datos:** La combinación exitosa de variables estructurales, espaciales (OpenStreetMap) y textuales (procesamiento de descripciones) mejoró significativamente la capacidad predictiva del modelo.
- **Validación espacial:** La implementación de validación cruzada espacial reveló estimaciones más realistas del error de generalización, evidenciando la importancia de considerar la autocorrelación espacial en datos georreferenciados.
- **Superioridad de XGBoost:** El modelo XGBoost superó consistentemente a otros algoritmos, logrando un R^2 de 0.87 y un RMSE de 105.7 millones de pesos en validación espacial.
- **Importancia de variables espaciales:** Las coordenadas geográficas (lat/lon) representaron 35 % de la importancia total del modelo, confirmando la relevancia de la ubicación en la valuación inmobiliaria.

4.2. Implicaciones Prácticas

Los resultados tienen implicaciones directas para la startup inmobiliaria:

- El modelo puede identificar propiedades subvaloradas o sobrevaloradas con una precisión aceptable
- La incorporación de variables de texto permite capturar señales de calidad no reflejadas en variables estructurales
- Las variables espaciales facilitan la evaluación de externalidades positivas por ubicación

4.3. Limitaciones y Trabajo Futuro

- **Datos de precios reales:** Se recomienda incorporar información de transacciones efectivas vs. precios de oferta para reducir sesgos
- **Variables temporales:** Incluir tendencias de mercado y estacionalidad podría mejorar las predicciones
- **Validación externa:** Evaluar el modelo en otras zonas de Bogotá o ciudades colombianas
- **Modelos interpretativos:** Desarrollar versiones más interpretables para facilitar decisiones empresariales

En síntesis, este estudio evidencia que la integración de técnicas de ciencia de datos, datos abiertos y procesamiento de lenguaje natural puede aportar soluciones efectivas y escalables para el análisis del mercado inmobiliario urbano en Colombia, proporcionando una base sólida para la toma de decisiones empresariales informadas.

Referencias

- Anthropic (2023). Conversaciones con claude ai assistant. Utilizado para estructura de documentos LaTeX, y mejoramiento del código en R.
- Castillo-Álvarez, G. and Sarmiento-Barbieri, I. (2024a). Data pre-processing: Visualizing and handling missing values (part 1). Notebook proporcionado como material del curso.
- Castillo-Álvarez, G. and Sarmiento-Barbieri, I. (2024b). Data pre-processing: Visualizing and handling missing values (part 2). Notebook proporcionado como material del curso.
- Chen, T. and Guestrin, C. (2016). Xgboost: A scalable tree boosting system. *arXiv preprint arXiv:1603.02754*.
- James, G., Witten, D., Hastie, T., and Tibshirani, R. (2021). *An Introduction to Statistical Learning: with Applications in R*. Springer, New York, NY, 2 edition.
- Naus (2025). Uniandes bdml 2025_10 ps3. <https://kaggle.com/competitions/uniandes-bdml-2025-10-ps-3>. Kaggle.
- News, B. (2021). Zillow shuts down home buying business, cites inaccuracy in algorithm. Disponible en: <https://www.bloomberg.com/news/articles/2021-11-02/zillow-quits-home-flipping-business>.
- OpenAI (2023). Conversaciones con chatgpt. Utilizado para estructura de documentos LaTeX, y mejoramiento del código en R.
- Rosen, S. (1974). Hedonic prices and implicit markets: Product differentiation in pure competition. *Journal of Political Economy*, 82(1):34–55.
- Sarmiento-Barbieri, I. (2024). Limpieza de datos con tidyverse. Notebook proporcionado como material del curso.